



SOURCE MERIDIAN · TECH SPHERE CHALLENGE 2026

Informe final MeridianAsiste

Agente de voz de seguimiento post-operatorio para pacientes colombianos: conversación adaptable, respuestas fundamentadas en un corpus clínico verificable, conocimiento que se actualiza en caliente y una decisión de escalamiento que no depende del modelo de lenguaje.

PARTICIPANTE	Alejandro Estrada Moscoso
CORREO	alesmo30@gmail.com
ENTREGABLE	03 · Informe final
REPOSITORIO	github.com/alesmo30/ts-sm
MODELO DECLARADO	llama-3.3-70b-versatile — familia Meta Llama, servido vía Groq
FECHA	12 de agosto de 2026

Contenido

0	Resumen ejecutivo	3
	Qué se construyó, en una página	
1	El problema y el alcance	4
	Qué pide el reto, qué quedó dentro y qué fuera	
2	Declaración del modelo	5
	Cuál se usó, por qué, y cómo se verifica	
3	Arquitectura de la solución	7
	Diagrama, capas, datos y arranque	
4	Conocimiento: recuperación, trazabilidad y actualización en caliente	9
	El RAG clínico y el conocimiento vivo	
5	Lógica de decisión y escalamiento	16
	Cómo decide alertar a un humano	
6	Diseño de la conversación y de los prompts	22
	El guion, las capas del prompt y su ajuste	
7	La capa de voz	24
	El camino del audio y sus decisiones	
8	Métricas y observabilidad	26
	Latencia, consumo y costo medidos	
9	Configuración del sistema	29
	Valores usados y umbrales calibrados	
11	El proceso de trabajo	30
	Método, uso de IA y cronología	
12	Límites conocidos y qué seguiría	31
	Deuda técnica y plan a dos semanas	
B	Anexo B · Mapa de la rúbrica	33
	Dónde se sustenta cada criterio	

Las figuras 1 y 4 constituyen el entregable O2 — diagrama de arquitectura de la solución y diagrama de flujo de decisión del agente. Los recuadros con borde punteado señalan capturas del demo pendientes de insertar, con la indicación exacta de qué debe mostrar cada una.

RESUMEN EJECUTIVO

00 • Qué se construyó

Una página para entender el sistema completo antes de entrar en detalle.

MeridianAsiste es un agente de voz que hace el seguimiento telefónico de un paciente recién operado. Conversa en español de Colombia, recorre las seis áreas del seguimiento post-operatorio sin recitarlas como un formulario, responde las dudas del paciente únicamente con lo que encuentra en el corpus clínico cargado, decide si el caso necesita un médico humano y deja un resumen estructurado con las fuentes que usó.

El sistema es un monolito modular de NestJS con Postgres y pgvector, más una aplicación web con dos superficies: la **interfaz de llamada** del paciente y la **consola del médico**. Todo levanta con un solo `docker compose up` y llega con la base de conocimiento ya poblada.

1

MODELO GENERATIVO
EN TODO EL SISTEMA

3.995

FRAGMENTOS CLÍNICOS
INDEXADOS EN ESPA-
ÑOL

4

SEÑALES INDEPEN-
DIENTES
QUE PUEDEN ESCALAR

≈US\$0,011

COSTO MEDIDO
POR CONVERSACIÓN

Las tres ideas que sostienen el diseño

1 • La decisión de escalar no la toma el modelo de lenguaje

Se midió que el modelo emitía la señal de alarma correctamente sólo el 40–50 % de las veces. La respuesta no fue insistir con el prompt: fue sacar la decisión de esa dependencia. Hoy cuatro señales independientes pueden disparar una alerta y **ninguna puede cancelar a otra**. En salud el falso negativo es la falla catastrófica, y toda la arquitectura de decisión está construida sobre esa asimetría.

2 • Sin fuente recuperada no hay afirmación clínica

Cada respuesta clínica se rastrea hasta el fragmento y el documento que la sustentan. Si el corpus no cubre la pregunta, el agente lo dice y ofrece pasarla al médico — tiene prohibido explícitamente responder con «recomendaciones generales de sentido común», porque eso también es inventar contenido clínico aunque suene razonable.

3 • El conocimiento cambia en caliente, y queda auditado

El médico sube un protocolo desde la consola y el agente lo usa en el turno siguiente, sin reiniciar nada; lo desactiva y lo olvida en el mismo instante. Cada turno guarda contra qué versión de la base de conocimiento se respondió, así que el antes y el después son verificables fuera de la demo.

Estado frente a las cinco compuertas eliminatorias

COM-PUERTA	QUÉ EXIGE	CÓMO LO RESUELVE ESTA ENTREGA
G1	Los cuatro entregables completos	Repositorio público con licencia MIT, diagramas de arquitectura y de decisión (§3 y §5 de este informe), este informe y el video.
G2	Levantable en 15 minutos o menos siguiendo sólo el README	<code>cp .env.example .env</code> y <code>docker compose up</code> . El contenedor de la API espera la base, migra, siembra el corpus y arranca. Sin ingesta de PDFs en el arranque: se corrió una sola vez y su resultado está versionado.
G3	Un modelo de una de las familias permitidas	<code>llama-3.3-70b-versatile</code> , familia Meta Llama vía Groq. Todo acceso al modelo pasa por un único punto del código; <code>GET /llm/health</code> lo declara en vivo. Ver §2.
G4	Conversación de voz en tiempo real	Reconocimiento con Deepgram Nova-3 en español y síntesis con Aura-2 en voz colombiana, por WebSocket. El modo texto está siempre disponible como respaldo.
G5	Subir y eliminar conocimiento desde la consola	Carga de archivo o texto con barra de progreso, e interruptor de activación por documento. El borrado es reversible y surte efecto en el turno siguiente. Ver §4.7.

Sobre la honestidad de las cifras de este informe

Todos los números provienen de corridas reales contra el modelo, la síntesis de voz y los embeddings reales, y están reproducidos tal cual quedaron — incluidos los que no favorecen. Cuando una métrica no se ejerció en una corrida se dice explícitamente en vez de rellenarla. La sección §8.5 lista, una por una, las mediciones que faltan y por qué.

SECCIÓN 01

01 • El problema y el alcance

Qué pide el reto, qué se construyó, y qué se dejó deliberadamente fuera.

1.1 El problema clínico

El paciente post-operatorio se va a casa el mismo día o al día siguiente. Ahí empieza la ventana en la que ocurren las complicaciones evitables: infección del sitio quirúrgico, sangrado, fiebre. Muchas veces nadie lo llama; cuando vuelve, vuelve por urgencias.

El seguimiento telefónico funciona clínicamente, pero no escala. Una enfermera alcanza a hacer unas veinte llamadas al día, y una proporción alta de ellas no encuentra nada accionable — es tiempo clínico caro gastado en confirmar que todo va bien. Además, las llamadas que sí se hacen rara vez dejan datos estructurados: quedan en una nota de texto libre que nadie agrega ni audita.

La oportunidad no es reemplazar a la enfermera: es **invertir la carga**. Que el 100 % de los pacientes reciba el seguimiento en las primeras 24 a 72 horas, y que el equipo humano reciba, priorizado y documentado, sólo el subconjunto que muestra señales de alarma.

1.3 Qué quedó dentro del alcance y qué no

Declarar el borde del alcance es parte del entregable: la rúbrica observa explícitamente «qué parte de lo que el reto pide quedó cubierta, qué quedó sin cubrir, y qué se construyó por fuera de lo pedido».

DENTRO	FUERA, A PROPÓSITO
Conversación de voz bidireccional en el navegador, con modo texto siempre disponible	Telefonía real de producción como canal principal (SIP, centralita)
Corpus clínico de los cinco procedimientos del kit oficial, indexado y consultable	Cobertura de todos los procedimientos quirúrgicos existentes
Consola del médico con dashboard, atención prioritaria y gestión de conocimiento	Integración con sistemas hospitalarios reales (HL7, FHIR, historia clínica electrónica)
Triage clínico determinístico y registro auditable de cada escalada	Autenticación empresarial, inicio de sesión único o gestión de roles
Métricas de latencia, consumo y costo emitidas automáticamente por turno	Persistencia histórica de métricas y tablero de observabilidad

Hay **una funcionalidad construida por fuera de lo pedido** y conviene señalarla en lugar de dejar que la encuentren: desde la vista de atención prioritaria el médico puede llamar al paciente o enviarle un correo, con el guion y el borrador redactados por el mismo modelo permitido. No es el núcleo de la solución ni compite por puntos; cierra el ciclo de la alerta, que de otro modo termina en una lista que alguien tiene que leer. El sistema completo funciona sin esas credenciales: los dos endpoints responden con un error explícito y la aplicación arranca igual.

SECCIÓN 02 · REQUISITO EXPLÍCITO DEL ENTREGABLE

02 · Declaración del modelo

Qué modelo se usó, por qué se eligió, y cómo se hace verificable en vez de simplemente declarable.

Declaración

El 100 % de la generación de lenguaje de este sistema se ejecuta con `llama-3.3-70b-versatile`, de la familia Meta Llama servida vía Groq — una de las cuatro familias permitidas por el kit oficial del reto. Cada palabra que el paciente lee o escucha, cada resumen clínico, cada reformulación de consulta y cada línea de la traducción del corpus salen de ese modelo y de ningún otro.

2.1 Por qué este modelo

Las familias permitidas eran cuatro: Gemini en su gama Flash, Meta Llama vía Groq, Llama local en CPU y Phi Mini local. Las dos opciones locales quedaron descartadas por la compuerta de levantamiento: descargar un modelo en el arranque consume el presupuesto de quince minutos, y correr inferencia en CPU en la máquina del jurado es un riesgo que no controla.

Entre las dos de nube, el criterio fue la **latencia**. En una conversación hablada el presupuesto de un turno completo — reconocer la voz, razonar, sintetizar la respuesta — es de pocos segundos, y el modelo compite

por ese presupuesto con el resto del sistema. Groq ejecuta sobre hardware especializado y entrega los tokens casi de inmediato.

La instrumentación posterior confirmó la decisión, aunque no de la forma esperada: el modelo resultó ser **la etapa más barata del turno**, con una mediana de 796 ms frente a 6.348 ms de embeddings y 6.645 ms de síntesis de voz (§8.4). El modelo no es el cuello de botella; lo que la elección compró fue quitarlo de la lista de sospechosos.

El costo de esa elección, dicho de frente

Llama 3.3 70B es poco fiable siguiendo **instrucciones condicionales de formato**: emitir una marca estructurada exacta sólo cuando se cumple cierta condición. Eso rompió el mecanismo de escalamiento y obligó a rediseñarlo. Esa historia — con los datos que la sostienen — está en §5.4, y es la decisión técnica más relevante del proyecto.

2.2 Cómo se hace verificable, no sólo declarable

Una declaración en un informe no vale nada si no se puede comprobar contra el código. El diseño la hace comprobable de cuatro maneras independientes:

MECANISMO	CÓMO SE COMPRUEBA
Un único punto de acceso al modelo. Ningún módulo del sistema importa un SDK de modelo de lenguaje; todo pasa por una clase abstracta de ocho líneas.	Buscar en el repositorio cualquier importación de un SDK de modelo: aparece únicamente dentro de la carpeta de drivers. Ningún módulo de dominio sabe qué modelo hay detrás.
Un solo driver activo , resuelto una vez al arrancar a partir de la configuración, y validado con un esquema que aborta el proceso nombrando la variable que falte.	La aplicación no arranca en un estado ambiguo: o la configuración es completa y coherente, o no levanta.
Cada llamada registra el modelo que el proveedor devolvió , no el que se pidió, junto con tokens, costo y latencia.	<code>GET /llm/metrics</code> y <code>GET /metrics</code> — las mismas cifras que aparecen en §8.
El modelo activo es consultable en caliente , sin leer código ni logs.	<code>GET /llm/health</code> responde con el proveedor, el modelo y si está listo.

```
$ curl localhost:3000/llm/health
{"provider":"openai","model":"llama-3.3-70b-versatile","ready":true}
```

Un detalle que conviene aclarar antes de que genere dudas

El driver se llama `openai` porque implementa el protocolo `chat.completions`, no porque hable con OpenAI. La dirección base apunta a `https://api.groq.com/openai/v1` y el modelo servido es Llama. **Ninguna clave de OpenAI interviene**, y no existe ningún proveedor de respaldo configurado: no hay un «plan B silencioso» que pudiera activarse durante la evaluación.

2.3 Los componentes no generativos

El reglamento restringe el **modelo de lenguaje que razona en el agente** y declara libre el resto del stack: «el reconocimiento de voz, la síntesis de voz, la base vectorial, los embeddings y el framework de orquestación

son decisión tuya». Estos son los componentes que se apoyaron en esa libertad, y por qué ninguno es un segundo modelo generativo:

COMPONENTE	SERVICIO	¿GENERA LENGUAJE?	NATURALEZA
Reconocimiento de voz	Deepgram Nova-3	No	Transcriptor acústico. Convierte audio en texto; no razona ni produce contenido propio.
Síntesis de voz	Deepgram Aura-2, voz es-CO	No	Lee en voz alta un texto que ya existe.
Embeddings	Google <code>gemini-embedding-001</code>	No	Codificador. Convierte texto en un vector de números; no emite un solo token legible.
Base vectorial	pgvector sobre PostgreSQL	No	Índice y operadores de distancia.
Razonamiento conversacional	Groq · llama-3.3-70b-versatile	Sí	El único modelo generativo del sistema.
Resúmenes, reformulaciones y traducción del corpus	El mismo modelo	Sí	Reutilización del modelo permitido, nunca un segundo modelo.

La tentación que se rechazó explícitamente

Hubo dos momentos en que un segundo modelo generativo habría sido la solución cómoda: normalizar el habla coloquial colombiana antes de evaluarla, y clasificar si un mensaje del paciente era una bandera roja. En los dos casos se resolvió sin generación: la normalización es un diccionario determinístico de 27 patrones (§5.3) y la clasificación es similitud de embeddings contra frases de alarma (§5.4). El código lleva el comentario que lo justifica en el sitio exacto donde la tentación aparecía. Un segundo modelo generativo «sólo para una tarea auxiliar» sigue siendo un segundo modelo.

SECCIÓN 03 · ENTREGABLE 02, PRIMERA PARTE

03 · Arquitectura de la solución

Cómo está partido el sistema, por qué así, y cómo levanta en menos de quince minutos.




Figura 1 — Arquitectura de la solución. Tres contenedores, un solo proceso de aplicación. Cada módulo del backend es una unidad con su propio controlador, servicio y repositorio. Todo acceso al modelo de lenguaje atraviesa un único punto.

3.1 Por qué un monolito modular y no microservicios

La compuerta de levantamiento pesa más que la elegancia arquitectónica. El jurado debe tener todo corriendo en quince minutos sobre una máquina limpia, y **cada servicio adicional es una imagen más que construir, un chequeo de salud más que puede fallar y un modo de fallo más el día de la evaluación.**

Un monolito modular da las mismas fronteras lógicas — los módulos son unidades de inyección de dependencias con su propio controlador, servicio y repositorio — sin pagar el costo operativo de la red entre procesos. Si esto tuviera que escalar a producción real, los módulos ya están cortados por donde se cortarían los servicios.

Lo que sí está separado en procesos son tres cosas: la base de datos, la API y la aplicación web, encadenadas por chequeos de salud para que ninguna arranque antes de que su dependencia esté lista.

3.2 Las capas del backend

Regla estricta, sostenida por convención y revisada en cada integración: **controlador → servicio → repositorio → base de datos**. Un controlador nunca toca la base directamente; un servicio nunca ve un objeto de petición o de respuesta HTTP. Cada módulo de dominio tiene la misma forma de cuatro archivos, más su archivo de pruebas que reemplaza el repositorio por un doble.

La **validación de entrada se aplica por ruta**, no globalmente, porque cada ruta necesita su propio esquema. Y el mismo esquema que valida la entrada en el servidor valida la respuesta en el cliente: hay una sola definición y dos puntos de verificación, de modo que **el cliente nunca confía ciegamente en la API**.

3.3 Modelo de datos

PostgreSQL 16 con la extensión pgvector, todo bajo un esquema propio. Las migraciones son archivos generados y versionados, nunca editados a mano y nunca aplicadas por sincronización automática.

La decisión de fondo — **una sola base en vez de Postgres más una base vectorial dedicada** — tiene tres razones y todas se defienden solas: el sistema necesitaba igual una base relacional para sesiones, transcripcio-

nes y escaladas; una sola imagen es un solo chequeo de salud; y permite hacer la búsqueda léxica y la semántica **en la misma consulta transaccional, sobre las mismas filas, con el mismo filtro de documento activo.**

TABLA	QUÉ GUARDA Y POR QUÉ IMPORTA
sessions	Una llamada. Guarda el nivel de triage y las áreas cubiertas por separado del semáforo visual, el resumen estructurado del cierre, y la versión de la base de conocimiento vigente.
transcripts	Cada turno, con sus citas y con la versión de conocimiento contra la que se respondió . Es el rastro de auditoría del conocimiento vivo.
references	Los documentos. El borrado es un interruptor de activación, no una eliminación.
reference_chunks	Los fragmentos. Llevan el texto en español, el original si se tradujo, un índice de texto completo generado por la propia base y el vector de embedding.
priority_patients	Las escaladas: resumen clínico, quién la pidió, en qué terminó. Una por sesión, garantizado por la base.
kb_state	Una única fila con la versión de la base de conocimiento. El reloj lógico de todo el sistema de conocimiento.

3.4 El arranque: la compuerta de los quince minutos

```
cp .env.example .env
docker compose up
```

El punto de entrada del contenedor de la API hace, en orden: espera a que PostgreSQL responda, aplica las migraciones, ejecuta el sembrado y arranca la aplicación. Es decir: **un levantamiento sobre un volumen vacío termina con la base poblada**, corpus clínico incluido, sin un solo comando manual.

La pieza que hace esto defendible es que **la ingesta de los 107 PDFs no ocurre en el arranque**. Se corrió una vez, fuera de línea, y su resultado — los fragmentos ya traducidos, indexados y comprimidos — está versionado en el repositorio. El jurado no espera a que se procesen documentos ni a que se descarguen modelos.

El sembrado es **transaccional e idempotente**: se apoya en claves naturales y puede volver a ejecutarse sin duplicar nada. Y el sistema arranca **sin ninguna credencial**: el driver de prueba del modelo no necesita clave, la voz queda desactivada y los servicios de embeddings degradan sin bloquear. Con credenciales queda completo; sin ellas, levanta igual.

SECCIÓN 04 · 20 PUNTOS DE LA RÚBRICA

04 · Conocimiento: recuperación, trazabilidad y actualización en caliente

Cómo el agente responde con el corpus del hospital y no con lo que el modelo cree recordar — y cómo aprende y olvida sin reiniciarse.

4.1 El corpus y la ingesta

El kit oficial trae **107 documentos clínicos en PDF**, repartidos en cinco procedimientos: apendicitis, colecistitis, cáncer colorrectal, cáncer de cuello uterino y reemplazo articular total. De ellos, **106 quedaron indexados en 3.995 fragmentos**, y **62 documentos contenían texto en inglés**.

Los PDFs **no se versionan** en el repositorio: conservan derechos de terceros y el repositorio es público bajo licencia MIT. Lo que sí se versiona es el resultado del procesamiento.




Figura 2 – El recorrido completo del conocimiento. Arriba, lo que se corrió una sola vez y quedó versionado. Abajo, lo que ocurre en cada turno del paciente.

4.2 Cómo se logró que el agente responda en español

Un corpus mitad en inglés y un paciente que pregunta en español colombiano es el problema central de este RAG, y no se resuelve con una sola medida. Se resolvió con seis capas que se refuerzan entre sí.

Capa 1 · El corpus entero se llevó al español, fuera de línea

Los 62 documentos con texto en inglés se tradujeron fragmento por fragmento al español de Colombia **con el mismo modelo permitido**, con temperatura cero y un prompt de traductor médico literal. No se usó un traductor automático ni un segundo modelo: el reglamento prohíbe un segundo modelo generativo, no reutilizar el único.

Fueron **1.967 fragmentos traducidos** — prácticamente la mitad del corpus. Costo medido de la operación completa: **alrededor de un dólar**. Se pagó una vez.

La caché de traducción, y por qué se escribe antes que la base

Cada documento traducido se guarda como archivo en disco, **versionado en el repositorio**. La clave no es el identificador del fragmento sino una huella del texto original: así la caché sobrevive a que se borre la base, a que cambie el esquema y a que se pierdan los PDFs. Y se escribe antes de actualizar la base de datos — si el proceso muere a la mitad, la llamada al modelo ya está pagada y guardada, y el reintento no la vuelve a pagar.

Se conserva además el **texto original en inglés** junto al español. Es lo que mantiene verificable el criterio de la rúbrica de que la referencia «resista una verificación contra la fuente real» también para los documentos traducidos.

No traduzco en tiempo real: traduje el corpus una sola vez, fuera de línea, con el mismo modelo permitido, y lo dejé en caché dentro del repositorio. El paciente nunca paga latencia ni tokens por el idioma en que estaba escrito el documento.

4.3 Búsqueda híbrida: las dos ramas

Cada turno lanza **en paralelo** una búsqueda léxica y una semántica sobre las mismas filas, y funde los resultados eliminando duplicados.

El enriquecimiento de la consulta, y sus dos excepciones

La consulta que se busca no es sólo el mensaje del paciente: es **la última pregunta del asistente más el mensaje del paciente**. Una pregunta de seguimiento corta — «¿y si sangra?» — no trae vocabulario clínico propio; la pregunta anterior sí.

Dos excepciones, ambas encontradas en pruebas manuales y ambas medidas:

- **El saludo se excluye.** Es texto genérico sin contenido clínico y concatenarlo diluye el vector de la consulta. Está medido: **0,70 de similitud sin el saludo frente a 0,64 con él**, contra el mismo fragmento — suficiente para tumbar una cita relevante por debajo del umbral.
- **En una despedida se salta la búsqueda entera.** Si no, el vocabulario clínico del turno anterior queda solo, sube la similitud contra documentos reales pero fuera de tema, y aparece una cita nueva sin que el paciente haya preguntado nada.

4.4 El filtro de relevancia de citas

El problema que resuelve. La búsqueda léxica devuelve sus mejores resultados en cuanto coincide una sola palabra, aunque sea genérica — «control», «cita» — y el documento no responda nada. El paciente veía citas de documentos irrelevantes incluso cuando el asistente decía honestamente que no tenía información sobre el tema.

Cómo funciona. Se codifica la pregunta y cada fragmento candidato, y se descartan los que quedan por debajo de **0,70 de similitud coseno**. Lo que sobrevive es lo que se le muestra al paciente y lo único que entra al prompt como material de fundamentación.

Este servicio es el mayor costo de latencia del sistema, y se reporta como tal

Codifica cada cita **una por una**, porque el proveedor de embeddings no ofrece codificación por lotes en modo síncrono. En la corrida instrumentada, la etapa de embeddings tiene una mediana de 6.348 ms, contando alrededor de doce llamadas por turno. Es el candidato número uno a optimizar y está identificado con datos, no por intuición (§8.4 y §11).

Una cifra que parece mala y no lo es



En la corrida instrumentada, una de las dos sesiones reporta **4,0 consultas de recuperación por turno**. No es un número inflado: es el costo real de una conversación cuyo vocabulario queda fuera de la cobertura del corpus — el filtro no encontró citas y disparó la reformulación en cada turno. Se reporta tal cual porque es exactamente el dato que un operador necesita para saber cuándo su corpus está incompleto.

4.6 Trazabilidad

Cada cita lleva el documento, el fragmento, la versión y el puntaje, más un extracto de 300 caracteres. Se guardan junto al turno, con la versión de la base de conocimiento vigente en ese momento. La interfaz las muestra como etiquetas bajo la respuesta y abre el fragmento completo en una ventana, con su documento de origen.

El detalle que separa trazabilidad real de trazabilidad decorativa

Si el modelo declaró que no tenía información — es decir, si la respuesta no se fundamentó en el material recuperado — **las citas recuperadas no se muestran**. Son sólo lo que trajo la búsqueda, no lo que sustentó la respuesta. Mostrarlas sería mentir sobre la fuente, y es exactamente el tipo de cosa que la rúbrica verifica contra el documento real.




Al abrir una referencia se ve el fragmento exacto del documento fuente — aquí, los signos de alarma post-operatorios de un plan de cuidado — con la versión del documento y la de la base de conocimiento del turno.

Interfaz de llamada. Cada respuesta del agente lleva debajo las referencias que la sustentan, y la marca «leído en voz alta» indica que además se sintetizó. La versión de la base de conocimiento del momento es visible en la cabecera.

Captura 1 — Una respuesta clínica con sus fuentes. El fragmento mostrado es el texto real del documento, no un resumen: es lo que permite verificar la cita contra la fuente. Nótese que la versión del documento y la de la base de conocimiento del turno se registran por separado.

4.7 Conocimiento vivo

Esta es la compuerta que más se subestima. «Olvidar» no es borrar un vector: hay que sacarlo de las dos ramas de búsqueda, invalidar lo que estuviera cacheado, y que las sesiones abiertas se enteren — todo sin reiniciar el sistema.



Olvidar es reversible: volver a activarlo lo devuelve, sin reindexar y sin reiniciar el sistema.

Figura 3 – Ciclo de aprender y olvidar. El médico sube o desactiva un documento y el efecto es inmediato sobre la conversación en curso. La versión de la base de conocimiento se incrementa dentro de la misma transacción.


Las cuatro decisiones que lo hacen funcionar

- **El borrado es un interruptor, no una eliminación.** Las dos ramas de búsqueda filtran por documento activo, así que desactivar hace desaparecer el conocimiento instantáneamente y sin reindexar. Y volver a activarlo lo recupera: olvidar es reversible.
- **La versión de conocimiento sube en la misma transacción** que el cambio. No hay un instante en que la base esté cambiada y la versión todavía no.
- **Cada turno graba contra qué versión respondió.** Ese es el rastro que hace auditable la demostración: se puede reconstruir después, desde la base, qué sabía el agente cuando dijo lo que dijo.
- **Las sesiones abiertas reciben aviso.** Aparece un divisor en la conversación del paciente indicando que la base de conocimiento se actualizó, y el prompt tiene instrucción explícita de no comentarlo ni retomar por su cuenta la pregunta anterior — el paciente no tiene por qué enterarse de la administración interna del sistema.


La ingesta corre en una **cola de un trabajo a la vez**, para que subir un documento durante una conversación no compita por el presupuesto de peticiones del chat. El médico ve el progreso por etapas: recibido, extrayendo, fragmentando, generando embeddings, indexado.

Un detalle operativo pensado para la demostración en vivo


La caché de traducción está montada desde el disco del anfitrión. Si el jurado sube un PDF en inglés durante la sesión, la traducción se paga al modelo una vez y **sobrevive a que se recree el contenedor**.




1 · El médico sube el documento desde la consola, sin tocar el servidor. La barra muestra la etapa en curso – aquí, generando embeddings – y debajo queda listado junto a las demás referencias subidas, cada una con su interruptor.



2 · En la conversación en curso aparece el divisor «Base de conocimiento actualizada · retorno-ejercicio-apendicectomia», y la siguiente respuesta ya cita ese documento entre sus fuentes.



3 · Ante una repregunta más específica que el corpus sigue sin cubrir, el agente responde «No tengo información confirmada sobre el momento exacto...» y ofrece pasarla al médico, en vez de improvisar una recomendación.



4 · El médico desactiva el documento. Queda listado como deshabilitado y con la opción de rehabilitarlo: olvidar es un interruptor reversible, no un borrado destructivo.

Captura 2 – La secuencia de conocimiento vivo, en cuatro momentos. Ningún paso requirió reiniciar el sistema. El divisor del segundo panel es el aviso que reciben las sesiones abiertas, y el agente tiene instrucción explícita de no comentarlo. El tercer panel muestra el comportamiento que la rúbrica busca: declarar el límite en vez de responder con generalidades.

SECCIÓN 05 · 20 PUNTOS DE LA RÚBRICA · ENTREGABLE 02, SEGUNDA PARTE

05 · Lógica de decisión y escalamiento

Cómo el sistema decide que un caso necesita un médico humano — y por qué esa decisión no depende del modelo de lenguaje.

En salud, el falso negativo pesa más que el falso positivo. Toda la arquitectura de decisión de este sistema está construida sobre esa asimetría.

5.1 El flujo completo

Este es el diagrama que corresponde a lo implementado. Cada caja tiene su contraparte en el código, y el orden del diagrama es el orden real de ejecución.




Figura 4 – Flujo de decisión del agente. El recorrido de un turno del paciente, desde que llega el mensaje hasta que se resuelve si hay que alertar a un humano. Las líneas punteadas rojas son las señales que entran a la decisión de escalar desde fuera del camino principal.

5.2 El triage determinístico

Una función pura, sin dependencias, sin entrada ni salida a disco y **sin modelo**. Recibe el texto del paciente y devuelve señales por área clínica.

ÁREA	AMARILLO	ROJO
Fiebre	temperatura $\geq 37,5$ °C	temperatura $\geq 38,5$ °C
Dolor	≥ 5 en escala de 0 a 10	≥ 8 en escala de 0 a 10
Movilidad	«me cuesta caminar», «cojeo», «dificultad para moverme»	«no puedo caminar / moverme / levantarme / pararme»
Herida	«un poco roja», «algo hinchada», «enrojecida»	cubierto por el backstop semántico
Apetito	«no tengo apetito», «perdí el apetito», «sin ganas de comer»	—
Sueño	«no puedo dormir», «duermo mal», «insomnio», «no descanso»	—

La regla de acumulación: dos amarillos hacen un rojo

Fiebre de 38,0, herida enrojecida y dolor 6 son, cada uno por separado, hallazgos leves. Juntos son la sospecha de infección postoperatoria que son. La regla es determinística, monótona y se explica en una frase — que es exactamente lo que se necesita de una regla clínica que va a tener que defenderse ante alguien.

La cobertura se registra, no se finge

El resumen de cierre graba qué áreas se cubrieron, cuáles quedaron pendientes y cuáles se confirmaron en bloque. Responde al criterio de la rúbrica sobre «si indaga antes de decidir, si decide sin indagar, o si no decide»: **un verde con tres de seis áreas cubiertas queda escrito como tal**, en vez de disfrazarse de alta clínica.

5.3 Normalización del habla coloquial colombiana

ETIQUETA	SIN NORMALIZAR	CON NORMALIZACIÓN	Δ
Verde	112 / 123	112 / 123	0
Amarillo	2 / 25	9 / 25	+7
Rojo	3 / 12	5 / 12	+2

El criterio de éxito estaba escrito antes de medir y se cumplió: **sube el recall de rojo y amarillo sin que caiga la precisión de verde**. El evaluador corre las dos pasadas en la misma ejecución, y la pasada sin normalizar reproduce exactamente la línea base — funciona como guardia contra regresiones.

Los límites del evaluador, dichos antes de que los pregunten

Esta matriz mide **sólo la rama determinística**. El backstop semántico y la señal del modelo no están incluidos, porque no son reproducibles fuera de línea sin costo. En producción esas dos señales **sólo pueden subir la severidad**. Por lo tanto un recall de rojos de 5 sobre 12 es **un piso, no el rendimiento del sistema completo**: es el número de la capa que puedo medir gratis, en integración continua y sin credenciales. Prefiero reportar un piso honesto que un número global que no puedo reproducir.

5.4 El problema del escalamiento — la decisión técnica más relevante

El diseño original tenía al modelo como única fuente de verdad para escalar: emitía una marca estructurada al final de su respuesta y el servidor la detectaba. Elegante, y completamente frágil.

El problema, medido

MENSAJE DEL PACIENTE	CON EL MODELO COMO ÚNICA SEÑAL
«Tengo sangrado muy fuerte por la herida de la cirugía.»	escaló
«Tengo sangrado muy fuerte por la herida.» (el mismo síntoma, sin tres palabras)	no escaló
«Tengo fiebre muy alta y me cuesta respirar.»	no escaló — dos intentos
«Necesito hablar con un médico humano ya mismo.»	inconsistente entre intentos
«Quiero hablar con un médico humano.»	escaló

Tasa de acierto: 40 a 50 %, sin patrón claro. Para un mecanismo de seguridad clínica, eso no es un defecto de ajuste: es una arquitectura equivocada.

Las cuatro alternativas evaluadas

OPCIÓN	VEREDICTO
Detección determinística en el servidor, en paralelo	Elegida — y extendida de una lista de patrones a similitud semántica, porque los pacientes reales no usan el vocabulario de una lista.
Una segunda llamada al modelo sólo para clasificar	Descartada — duplica tokens y latencia en cada turno, y esos tokens entran en las métricas evaluadas. Pero sobre todo: sigue dependiendo del mismo modelo poco fiable. No resuelve el problema de raíz.
Cambiar de modelo	Fuera de alcance — la compuerta del modelo fija las familias permitidas.
Aceptar el riesgo y documentarlo	Inaceptable — es literalmente la conducta que la rúbrica califica como falla catastrófica.

La calibración del umbral — el detalle que separa un número medido de uno inventado

El valor inicial fue 0,51, de leer literalmente «mayor al 51 %». En prueba de punta a punta, el mensaje benigno «Hola, todo bien, sólo quería confirmar mi cita de control» escaló por error con un puntaje de **0,668**. La razón: en un dominio acotado como el médico, **la similitud base entre dos frases cualesquiera ya ronda 0,60 a 0,78**. El umbral que parecía razonable en abstracto era ruido dentro de la distribución real.

Se recalibró midiendo la distribución: los negativos llegaban como máximo a **0,776**; los positivos empezaban en **0,879**. Se fijó en **0,83**, con margen a ambos lados.

CASO DE PRUEBA	PUNTAJERESULTADO
«Tengo sangrado muy fuerte por la herida de la cirugía.»	0,951 escala
«Tengo sangrado muy fuerte por la herida.»	1,000 escala
«Tengo fiebre muy alta y me cuesta respirar.» (fallaba el 100 % antes)	0,888 escala

CASO DE PRUEBA

PUNTAJERESULTADO

«Necesito hablar con un médico humano ya mismo.»

0,994 **escala**

«Quiero hablar con un médico humano.»

0,993 **escala**

Paráfrasis que no está en ninguna lista — «me sale un líquido raro y la tengo súper roja e hinchada»

0,879 **generaliza**

Control negativo — «Hola, todo bien, quería confirmar mi cita»

0,668 **no escala**

De 40–50 % a seis de seis, incluida una paráfrasis que no figura en ninguna lista — que es la prueba de que generaliza y no memoriza. Y el control negativo dejó de dar falso positivo.

No resolví la causa raíz: la fiabilidad del modelo para formato condicional sigue siendo la misma. Lo que hice fue sacar la decisión de escalar de la dependencia exclusiva de esa fiabilidad. Cuatro señales independientes, unidas por una disyunción; la del modelo es sólo una de ellas.

5.5 Los cuatro disparadores




Figura 5 — Las cuatro señales de escalada y lo que producen. Cualquiera basta para escalar. Ninguna puede cancelar a otra. Si la señal viene de fuera del triage numérico, el nivel se fuerza igualmente a rojo: nunca puede quedar una sesión escalada pintada de verde en el panel del médico.

La defensa contra manipulación es arquitectónica, no textual

Por qué un intento de inyección de prompt no cambia la decisión clínica

Hay un bloque anti-manipulación al final del prompt, en la posición donde el modelo pone más peso (§6.5). Pero la defensa real es otra: **la decisión que importa no la toma el modelo**. Un atacante que convenga al modelo de no escalar sigue teniendo enfrente el triage determinístico y el backstop semántico, que no leen instrucciones — sólo miden números y similitud. La clasificación de riesgo no es texto que se pueda negociar.



Lado del paciente: el caso queda marcado para revisión prioritaria y se le avisa que un médico lo contactará al celular o al correo que registró. La cuenta regresiva es cancelable — «seguir hablando» — y cancelarla no borra el registro.



Lado del médico: la ficha en atención prioritaria, con el resumen clínico generado, el desenlace, la duración de la llamada y los botones de contacto al paciente.

Captura 3 – Una escalada completa, de punta a punta. El resumen nombra los síntomas concretos — «reportó sangrado muy fuerte por la herida quirúrgica» — y registra que el paciente había minimizado antes, que es justamente el patrón que hace peligroso confiar en el tono del relato.

5.6 El cierre estructurado

Al terminar la conversación se genera un resumen. El reparto de responsabilidades es la parte importante:

CAMPO	LO PRODUCE	POR QUÉ
Resumen de una línea, recomendaciones dadas y alertas reportadas	El modelo	Es redacción sobre una conversación que ya ocurrió — exactamente para lo que sirve un modelo de lenguaje.
Si el caso escaló	El servidor	Sale del máximo determinístico del triage. Si el modelo pudiera escribir este campo, la regla de que la severidad sólo sube dejaría de ser determinística justo en el campo que la rúbrica mira.
Cobertura de las seis áreas	El servidor	Es un hecho contable, no una interpretación.

CAMPO	LO PRODUCE	POR QUÉ
Métricas de la sesión	El servidor	Ídem.

Hay **tres formas de cerrar** una sesión: que el paciente deje expirar la cuenta regresiva tras una escalada; que confirme el cierre por chat; o por inactividad, con un proceso que cierra toda sesión sin actividad durante diez minutos. Esa ventana de diez minutos es también la tolerancia a una desconexión: recargar la página no debe perder la conversación.

Una fricción real que sólo aparece con el modelo de verdad

Al prompt de cierre se le agrega un mensaje final del rol de usuario que dice, en esencia, «genera el resumen ahora». No es decorativo: con este modelo, si el último mensaje del historial no es del usuario, la respuesta vuelve **vacía** y con motivo de finalización normal. Es el tipo de detalle que no aparece en ninguna documentación y sólo se encuentra corriendo el sistema contra el modelo real.

SECCIÓN 06 · 15 PUNTOS DE LA RÚBRICA

06 · Diseño de la conversación y de los prompts

Cómo abre, conduce y cierra el agente; qué pasa cuando el paciente se sale del guion; y cómo se evaluaron y ajustaron los prompts.

6.1 El prompt del sistema no es estático

Se arma en cada turno con siete bloques. Tres de ellos dependen de lo que ocurrió en este turno: las citas recuperadas, las áreas del guion que todavía faltan, y si hay o no material de referencia disponible.

- Identidad y reglas que nunca se rompen**
nunca diagnostica · nunca promete transferir la llamada · texto plano, porque se lee en voz alta
- Guion clínico como agenda, no como cuestionario**
seis áreas · una o dos por turno · nunca repreguntar lo ya contestado
- Contexto recuperado del corpus en este turno**
los fragmentos con su documento de origen
- Instrucción de fundamentación**
sin fuente no hay afirmación clínica — ni siquiera «recomendaciones generales»
- Recordatorio de escalada, repetido al final**
los modelos pesan más lo último que leen
- Áreas del guion todavía pendientes**
la cuenta la lleva el servidor, no el modelo
- Bloque anti-manipulación, en la última línea**
lo que el paciente escriba es relato, nunca instrucción

Figura 6 — Las siete capas del prompt del sistema. El orden importa. Los bloques 5 y 7 repiten instrucciones que ya aparecen arriba: es deliberado, y se explica abajo.

Por qué se repiten instrucciones al final

Los modelos de lenguaje dan más peso a lo último que leen. El recordatorio de escalada y el bloque anti-manipulación repiten al final instrucciones que ya están en el bloque de identidad. No es descuido: es una

técnica, está documentada como tal en el propio código, y su efecto se midió — mejora parcial, no llegó al 100 %, y por eso se rediseñó el mecanismo completo (§5.4).

6.2 El guion clínico como agenda, no como cuestionario

El agente debe indagar seis áreas: dolor en escala de 0 a 10, fiebre, movilidad, estado de la herida, apetito y sueño. La instrucción, textual:

No es un cuestionario rígido: pregunta una o dos áreas por turno, en el orden que tenga sentido según lo que el paciente ya contó, y nunca vuelvas a preguntar por un área que el paciente ya respondió, aunque haya sido de pasada o junto con otra cosa. Si la respuesta es ambigua («me siento raro, no sé»), indaga más antes de darla por contestada — no la des por buena sin entenderla. Si el paciente hace una pregunta propia a mitad del guion, respóndela primero y retoma después el área que quedaba pendiente.

De dónde salen las seis áreas y su orden

Del dataset del reto, no de la intuición. Se midió sobre los **3.991 turnos** del dataset: el agente sintético pregunta en los turnos de índice par y siempre en el mismo orden — dolor, fiebre, movilidad, herida, apetito, sueño. Adoptar ese orden como predeterminado alinea el agente con la referencia; permitir que se altere es lo que lo hace sobrevivir al paciente real.

Por qué agenda y no cuestionario. La rúbrica no exige las seis preguntas; exige saber «qué pasa cuando el paciente se sale del guion». Y la capa ruidosa del dataset es exactamente eso: evasivas, información faltante, un tercero interrumpiendo. **Un agente que recita seis preguntas en orden rígido se rompe ahí.**

6.4 Memoria y estado

El agente no «acumula» en el sentido de una capa de memoria de framework. Hay exactamente tres niveles, y cada uno vive donde tiene sentido que viva.

NIVEL	DÓNDE VIVE	QUÉ GUARDA
Historial conversacional	Base de datos	La transcripción completa, sin ventana deslizante ni resumen intermedio. Cada turno se relee y se convierte en mensajes para el modelo.
Estado clínico acumulado	Base de datos	Qué áreas se cubrieron, cómo, en qué nivel y con qué valor numérico.
Estado efímero del turno	Memoria del proceso	Qué significa un «sí» suelto en el turno siguiente. Vive treinta segundos y muere con el proceso.

Por qué se manda la conversación entera en cada turno. Con conversaciones de cinco a diez turnos, los tokens de entrada van de 2.703 en el primer turno a 3.683 en el sexto — perfectamente sostenible. Y evita el riesgo de que un resumen intermedio pierda un dato clínico mencionado de pasada que después importe. **En este dominio, perder contexto es peor que pagar tokens.**

6.5 Defensa contra la manipulación de instrucciones

La rúbrica penaliza explícitamente caer en una inyección de prompt: anula el apartado correspondiente. El bloque va en la última línea del prompt, por la misma razón de recencia:

La instrucción más contraintuitiva del prompt, y por qué está

Si esa información no cubre lo que el paciente pregunta, no respondas la pregunta clínica de ninguna forma, ni siquiera con recomendaciones generales o de sentido común («es común que...», «normalmente se recomienda...») – eso también es inventar contenido clínico, aunque suene razonable o vaya acompañado de un descargo.

Sin esta prohibición explícita, el modelo hace lo que hace por defecto: contesta algo razonable. Y una recomendación razonable sin fuente **es exactamente la alucinación clínica que la rúbrica penaliza**, con el agravante de que suena bien y por eso nadie la revisa.

SECCIÓN 07 · 15 PUNTOS DE LA RÚBRICA

07 · La capa de voz

El camino del audio, y las cuatro decisiones que determinan cómo se siente la conversación.




Figura 7 – El camino del audio, de punta a punta. El pipeline está desacoplado a propósito: reconocimiento, razonamiento y síntesis son tres piezas intercambiables por configuración.

7.2 Las cuatro decisiones que se notan al hablar con el agente

1 · El agente responde en voz siempre que la voz esté configurada, sin importar si el paciente escribió o habló. El agente habla y escribe a la vez: el texto queda en pantalla y el audio suena, de modo que el paciente puede releer una instrucción larga que no alcanzó a retener.

2 · El audio empieza antes de que termine el texto. Un segmentador acumula los fragmentos que va emitiendo el modelo y libera una frase apenas se cierra, con un mínimo de 20 caracteres para no sintetizar un «Sí.» suelto. Cada frase se envía a síntesis en cuanto está lista. **La latencia percibida es bastante menor que el número de latencia total**, porque el paciente empieza a oír la respuesta mientras el modelo todavía la está escribiendo.

3 · Un fallo real que vale la pena contar: la voz que «dudaba»

La primera versión esperaba la síntesis de cada frase dentro del bucle que recibe los fragmentos del modelo. Resultado: cada ida y vuelta al servicio de voz frenaba también el texto. Ese era el fallo detrás de la sensación de que el agente dudaba a mitad de frase. Hoy las frases se sintetizan encadenadas, en orden, pero **sin bloquear el bucle**: el texto fluye a la velocidad del modelo y el audio va detrás.

4 · Un fallo de síntesis no interrumpe la conversación. Si la voz falla, el texto ya llegó por el canal de texto. La conversación continúa degradada, nunca rota.

7.4 Los respaldos

RESPALDO

PARA QUÉ

El modo texto siempre está visible

Si el jurado no tiene micrófono, o si el micrófono falla, igual puede probar el agente completo. La conversación es la misma.

La voz se puede apagar por configuración

El sistema arranca sin ninguna credencial de voz, en modo texto puro.

Reconocimiento del navegador como alternativa

Existe como respaldo si el servicio externo no responde.

La transcripción no se autoenvía

Cae en el compositor y es editable. El paciente puede dictar, corregir a mano, dictar más y recién entonces enviar. Es también la defensa práctica contra una transcripción mala: se corrige antes de que llegue al agente.



El turno del paciente llega marcado como «transcrito de audio»; la respuesta del agente muestra el estado de síntesis en curso. El compositor de texto sigue disponible junto al micrófono, y el control de velocidad de voz permite bajar el ritmo para instrucciones largas.

Captura 4 – Conversación de voz en curso. El agente abre presentándose como asistente automatizado de seguimiento y va directo a la primera área del guion. La transcripción cae en el compositor y es editable: el paciente puede dictar, corregir y completar antes de enviar.

SECCIÓN 08 · MÉTRICAS OBLIGATORIAS

08 · Métricas y observabilidad

Latencia, consumo y costo — medidos automáticamente por turno, y reportados incluyendo lo que no se midió.

8.2 Los dos tramos de latencia

TRAMO	DESDE → HASTA	QUÉ INCLUYE
Latencia de respuesta	Entrada del mensaje → primer fragmento de audio	Sólo el sistema: recuperación, modelo y primera frase sintetizada. No incluye reconocimiento ni la red hacia el navegador.
Latencia desde el fin del habla	Fin de la transcripción → primer fragmento de audio	Es el tramo que pide la rúbrica. Medido en el servidor; no incluye la ida y vuelta de red hacia el navegador ni la reproducción en el parlante.

8.3 Corrida real — dos conversaciones completas

Dos conversaciones contra el modelo real, la síntesis de voz real y los embeddings reales, sin simulaciones, sobre el corpus del reto ya sembrado.

	SESIÓN A	SESIÓN B	AGREGADO
Turnos del paciente	6	5	11
Latencia de respuesta P50 / P95 (ms)	5.432 / 8.038	6.235 / 9.427	6.091 / 9.410
Tokens de entrada	19.894	15.180	35.074
Tokens de salida	613	386	999
Invocaciones al modelo (por turno)	6 (1,0)	5 (1,0)	11 (1,0)
Consultas de recuperación (por turno)	8 (1,33)	20 (4,0)	28
Llamadas de codificación (no son el modelo)	96	155	251
Costo estimado (USD)	0,0122	0,0093	0,0215

1,0

INVOCACIONES AL MODELO
POR TURNO — EXACTAMENTE UNA

6.091 ms

LATENCIA DE RESPUESTA
MEDIANA

≈US\$0,011

COSTO POR CONVERSACIÓN COMPLETA

2.703→3.683

TOKENS DE ENTRADA
DEL TURNO 1 AL 6

La tarifa aplicada es la pública del proveedor — 0,59 y 0,79 dólares por millón de tokens de entrada y salida — y está marcada como tal en el código, sin confirmar contra la consola de la cuenta. Se dice porque la rúbrica desempata por «menor costo por llamada reportado y verificado», y un número sin verificar no debe presentarse como verificado.

Las dos sesiones terminaron escaladas, y se reporta así

Una de las dos estaba pensada para cerrar sin novedad, y escaló porque dos áreas en amarillo acumularon a rojo. **No fue el guion buscado, y se reporta tal cual en vez de repetir la corrida hasta obtener el resultado bonito.** La asimetría es deliberada: prefiero revisar un caso de más que dejar pasar uno.

8.4 Dónde se va el tiempo de verdad

La latencia total dice cuánto tardó el turno, pero no dónde se fue el tiempo. Se instrumentó por etapa, y el resultado es contraintuitivo.




Figura 8 – Latencia por etapa – corrida real de 4 turnos. Barra sólida: mediana. Barra clara: percentil 95.

La etapa de embeddings, ella sola, es más larga que el turno completo. No es una contradicción: las etapas se solapan a propósito, y esa etapa cuenta las doce llamadas que dispara el filtro de relevancia, una por cita. El modelo de lenguaje, que es lo que todo el mundo asume que es el cuello de botella, tiene una mediana de 796 ms: una fracción menor del turno. Si tuviera dos semanas más, el primer cambio sería agrupar o cachear embeddings, no cambiar de modelo.

El informe declara además que las etapas de recuperación y de codificación **se solapan a propósito** y que su suma no equivale a la latencia total, porque la búsqueda incluye la codificación de la consulta. Restar el solape daría un número más limpio pero mentiroso.

8.5 Lo que no se midió, y por qué

Esta sección existe porque la rúbrica contrasta lo reportado con lo que ocurre en la sesión de evaluación, y porque reportar números que no se sostienen es peor que no reportarlos.


MÉTRICA

ESTADO Y MOTIVO

Latencia desde el fin del habla	Cero muestras, incluso en sesiones conducidas por voz. Es el hueco de medición más visible de la entrega y se declara sin adornos: el tramo sólo se computa cuando el turno recibe la marca de fin de transcripción del mismo socket, y en las corridas capturadas esa marca no llegó a consumirse. El mecanismo está cubierto por pruebas automatizadas — la marca se toma al terminar la transcripción y se consume en el turno siguiente, una sola vez — pero no hay una corrida que lo poblara. La latencia de respuesta, que sí tiene muestras, mide el mismo camino menos el reconocimiento de voz.
Latencia de reconocimiento de voz	Cero muestras por construcción : la transcripción ocurre durante el evento de cierre de audio, fuera del ámbito de medición del turno, y la instrumentación descarta lo que llega sin turno activo. Es una consecuencia conocida del diseño de la instrumentación, no un fallo intermitente. La síntesis de voz sí se mide en todas las corridas.
Verificación de la tarifa	Se usa la tarifa pública publicada, no la confirmada contra la consola de la cuenta. Marcado explícitamente en el código con el valor <code>tarifa_publica</code> , visible en la captura de abajo.
Persistencia de las métricas	Se acumulan en memoria y mueren con el proceso. Declarado en el README; no hay almacenamiento histórico.

Por qué esto se cuenta en vez de esconderse

Sería trivial reportar la latencia de respuesta como si fuera el tramo que pide la rúbrica: los dos números se parecen y nadie lo notaría hasta contrastar los logs. Pero la rúbrica penaliza explícitamente las métricas inconsistentes con los registros, y una entrega clínica que redondea a su favor en lo que se puede verificar no merece que le crean lo que no se puede. El hueco está identificado, tiene causa conocida y está recogido en el plan de §12.2.



```

{
  "model": "llama-3.3-70b-versatile",
  "provider": "openai",
  "pricing": {
    "inputPerMTokUsd": 0.59,
    "outputPerMTokUsd": 0.79,
    "source": "tarifa_publica"
  },
  "observedTurns": 10,
  "overall": {
    "responseLatency": {
      "count": 9,
      "p50Ms": 5580,
      "p95Ms": 7644,
      "minMs": 2742,
      "maxMs": 7910
    },
    "endOfSpeechLatency": {
      "count": 0,
      "p50Ms": null,
      "p95Ms": null,
      "minMs": null,
      "maxMs": null
    },
    "inputTokens": 32569,
    "outputTokens": 536,
    "costUsd": 0.01963915,
    "llmCalls": 10,
    "embeddingCalls": 117,
    "ragQueries": 10,
    "stageLatency": {
      "rag": {
        "count": 7,
        "p50Ms": 996,
        "p95Ms": 2209.7,
        "minMs": 561,
        "maxMs": 2396
      },
      "embedding": {
        "count": 10,
        "p50Ms": 11210,
        "p95Ms": 24919.75,
        "minMs": 602,
        "maxMs": 34534
      },
      "llm": {
        "count": 10,
        "p50Ms": 762.5,
        "p95Ms": 942.35,
        "minMs": 552,
        "maxMs": 959
      },
      "stt": {
        "count": 0,
        "p50Ms": null,
        "p95Ms": null,

```

Respuesta de GET /metrics tras una sesión real: modelo activo, tarifa aplicada, latencias agregadas y por etapa, tokens, invocaciones al modelo y costo.

Captura 5 – Las métricas del sistema, en vivo. Corresponde a una sesión posterior a la reportada en §8.3 – de ahí que los agregados difieran – y confirma el mismo patrón: el modelo declarado aparece en la propia respuesta y no en un archivo de configuración; las invocaciones al modelo son diez para diez turnos observados, exactamente una por turno; la etapa de embeddings vuelve a dominar el turno (mediana 11.210 ms) frente a un modelo de 763 ms; y los contadores de reconocimiento de voz y de latencia desde el fin del habla están en cero, tal como se declara arriba.

SECCIÓN 09 · EVIDENCIA DE CONFIGURACIÓN

09 · Configuración del sistema

Qué se puede configurar, qué valores se usaron y de dónde salió cada número.

9.1 Configuración activa

Toda la configuración vive en variables de entorno con un archivo de ejemplo comentado. Nunca se versiona el archivo real. Estos son los valores de la entrega, con las credenciales omitidas:

```
# — Modelo de lenguaje —————
LLM_PROVIDER=openai                # driver de protocolo, no proveedor
LLM_MODEL=llama-3.3-70b-versatile  # familia Meta Llama – compuerta G3
OPENAI_BASE_URL=https://api.groq.com/openai/v1
OPENAI_API_KEY=<clave de Groq>

# — Voz —————
VOICE_PROVIDER=deepgram            # «off» deja el sistema en modo texto puro
DEEPGRAM_STT_MODEL=nova-3
DEEPGRAM_TTS_MODEL=aura-2-celeste-es
DEEPGRAM_API_KEY=<clave>

# — Embeddings (codificador, no generativo) —————
GEMINI_EMBEDDING_MODEL=gemini-embedding-001
GEMINI_API_KEY=<clave>

# — Umbrales calibrados —————
ESCALATION_SIMILARITY_THRESHOLD=0.83  # backstop de banderas rojas
CITATION_RELEVANCE_THRESHOLD=0.70    # filtro de relevancia de citas

# — Base de datos —————
DATABASE_URL=postgres://postgres:postgres@db:5432/tssm
```

9.2 Los dos umbrales, y de dónde salen

UMBRAL	VALORCÓMO SE FIJÓ
Similitud de escalada	0,83Midiendo la distribución real: los mensajes benignos llegaban como máximo a 0,776 y los casos de alarma empezaban en 0,879. Se fijó en el medio, con margen a ambos lados. El valor inicial — 0,51, de leer «mayor al 51 %» — producía falsos positivos con mensajes inocuos. No mover sin recalibrar.
Relevancia de citas	0,70Es el corte por debajo del cual un fragmento coincide en alguna palabra pero no responde. Está acoplado a la dimensionalidad del codificador usado en ese filtro; cambiar una cosa obliga a recalibrar la otra.

SECCIÓN 11 · 15 PUNTOS DE LA RÚBRICA

11 • El proceso de trabajo

Cómo se construyó, cómo se trabajó con IA, y qué rastro quedó de las decisiones — incluidas las que salieron mal.

11.1 Un método de especificación antes de código

El proyecto se construyó especificación por especificación. Hay **catorce especificaciones numeradas** más tres documentos de problema y de pruebas manuales, todas versionadas en el repositorio. Cada una es autocontenida y tiene la misma forma:

Buena parte de las justificaciones de este informe — por qué no un índice vectorial aproximado, por qué no traducir en tiempo real, por qué el guion es agenda y no cuestionario — están tomadas literalmente de esas secciones. No se escribieron para el informe: se escribieron mientras se decidía.

Cada especificación se implementó en **su propia rama, con su propia integración revisada**. Nunca hubo una integración directa a la rama principal: son dieciocho integraciones revisadas sobre diecinueve confirmaciones de cambios.

11.2 Cómo se trabajó con IA

La rúbrica pregunta explícitamente por esto. La respuesta honesta es que la IA fue el par de programación durante todo el proyecto, y que lo que hizo la diferencia no fue usarla sino **cómo se le acotó el contexto**:

ARTEFACTO	FUNCIÓN EN EL FLUJO DE TRABAJO
Un archivo de restricciones del reto	Escrito antes de programar y releído antes de cada decisión técnica: las compuertas eliminatorias, la interpretación de la regla del modelo, las reglas de seguridad clínica y las reglas de arquitectura derivadas. No es documentación — es el conjunto de restricciones que, si se violan, invalidan el trabajo completo. Cuando llegó la duda sobre si el modelo en uso era válido, la respuesta ya estaba escrita ahí, junto con el criterio para resolverla.
Un archivo de contexto del repositorio	Documenta la arquitectura, los comandos, y sobre todo las trampas conocidas : por qué el paquete compartido tiene paso de compilación, por qué la caché del servidor de desarrollo se queda vieja dentro del contenedor y con qué comando exacto se arregla. Cada fricción que costó tiempo una vez quedó escrita para no costarlo dos veces.
Un contrato visual congelado	Los tokens de diseño y las reglas de la interfaz, fijados de entrada. Evitó rediscutir decisiones visuales en cada pantalla. Nota honesta: la rúbrica declara que la estética no puntúa. Fue trabajo bien hecho que no suma puntos — pero tampoco los resta, y hizo la construcción más rápida.
Revisión automática de cada integración	Un flujo de integración continua revisa cada cambio antes de integrarlo, además de ejecutar análisis estático, verificación de tipos, pruebas y compilación.
Documentos de problema	Cuando algo falló de forma no trivial, se escribió un documento con la reproducción, las hipótesis, los intentos fallidos y la resolución — antes de arreglarlo. §5.4 y el fallo de confirmación de cierre de §6.4 salen de ahí.

El patrón que se repite en todo el proyecto: escribir la restricción antes que el código, medir antes de optimizar, y dejar por escrito el «no» con su razón en el momento en que se decide. Un informe se puede escribir el último día; un rastro de decisiones, no.

SECCIÓN 12

12 · Límites conocidos y qué seguiría

Lo que este sistema no hace bien todavía, dicho antes de que lo pregunten.

12.1 Deuda técnica reconocida

LÍMITE	ESTADO
El filtro de relevancia codifica cita por cita — alrededor de doce llamadas HTTP por turno, mediana de 6.348 ms	Es el mayor costo de latencia del sistema y está medido, no supuesto. El proveedor de embeddings no ofrece codificación por lotes en modo síncrono; la solución es agrupar o cachear. Candidato número uno.
Sin índice vectorial aproximado	Decisión consciente: con 3.995 fragmentos el recorrido exacto alcanza y es más simple de razonar. Se rompe si el corpus crece un orden de magnitud.
Las métricas viven en memoria	Mueren con el proceso. Declarado en el README. No hay tablero histórico.
El estado efímero vive en el proceso	Dos instancias de la API romperían el consentimiento y la confirmación de cierre. No es un problema hoy — hay un solo contenedor — pero es una barrera real a escalar horizontalmente.
Las métricas por sesión del resumen de cierre van en cero	Los valores existen en el endpoint de métricas pero no se copian al resumen estructurado. Está declarado como decisión en la especificación correspondiente, no es un olvido.
Latencia mediana cercana a 6 segundos	Alta para una conversación de voz en vivo. No se esconde: está desglosada por etapa en §8.4, y el diagnóstico apunta a embeddings y síntesis, no al modelo. La latencia percibida es menor, porque el audio empieza en cuanto la primera frase está lista.
Recall de rojos del triage determinístico: 5 de 12	Es un piso medido de la única capa evaluable sin costo, no el rendimiento del sistema completo. Ver §5.3.

12.2 Qué haría con dos semanas más

1 • Agrupar o cachear los embeddings del filtro de citas

Es el cambio de mayor impacto en latencia percibida y no toca el modelo. La instrumentación por etapa lo señala sin ambigüedad: la etapa que todo el mundo asume que es el cuello de botella no lo es.

2 • Cerrar el evaluador sobre el sistema completo

Hoy mide sólo la rama determinística contra 160 casos. Quiero el número de las cuatro señales juntas, corriendo contra el dataset entero. Es lo que convierte «creo que funciona» en «sé cuánto funciona» — y es la diferencia entre un sistema clínico defendible y uno que se defiende con anécdotas.

3 • Un reordenador de tipo codificador cruzado entre la búsqueda y el prompt

El filtro de relevancia actual es similitud coseno con umbral fijo: compara dos vectores calculados por separado. Un codificador cruzado decide relevancia mirando la pregunta y el fragmento juntos, y es sustancialmente mejor en eso. No viola la regla del modelo: es un clasificador de relevancia, no un generador.

4 · Cerrar los huecos de medición

Una corrida completa con micrófono real para poblar la latencia desde el fin del habla y la de reconocimiento, y confirmar la tarifa contra la consola de la cuenta para poder reportar el costo como verificado y no como estimado sobre tarifa pública.

ANEXO B

B · Mapa de la rúbrica

Dónde se sustenta cada criterio, para que no haya que buscarlo.

B.1 Las cinco compuertas eliminatorias

	COMPUERTA	SUSTENTO
G1	Los cuatro entregables	Este documento es el entregable O3. Los diagramas del entregable O2 son las figuras 1 y 4.
G2	Levantable en ≤15 minutos	§3.4 · Captura 11
G3	Modelo de una familia permitida	§2 completa · Captura 10
G4	Conversación de voz en tiempo real	§7 · Captura 4
G5	Conocimiento vivo desde la consola	§4.7 · Capturas 2 y 8

B.2 Los seis criterios de puntuación

PTSCRITERIO	DÓNDE
20RAG, precisión clínica y conocimiento vivo	§4 completa. Respuestas fundamentadas (§4.6), qué hace ante lo que no sabe (§6.6, última parte), comportamiento al cambiar el conocimiento (§4.7), trazabilidad verificable contra la fuente (§4.2, capa 1, y §4.6).
20Lógica de decisión y escalamiento	§5 completa. Clasificación de criticidad (§5.2), qué hace ante la ambigüedad (§5.2 y §6.2), qué produce al alertar (§5.5), qué queda al terminar (§5.6).
15Comprensión del problema y diseño de la conversación	§1 y §6. Apertura, conducción y cierre (§6.2, §6.4, §5.6), qué pasa cuando el paciente se sale del guion (§6.2), alcance declarado (§1.3), correspondencia entre diagrama e implementación (figuras 1 y 4).
15Calidad de la conversación (voz)	§7. Tono y longitud (§6.1), latencia y qué ocurre durante los silencios (§7.2, §8), entradas adversas: jerga regional (§5.3) e intentos de manipulación (§6.5 y §5.5).
15Video de argumentación y demo	Fuera de este documento. Las respuestas a las dos preguntas de cierre se sustentan en §5.4 y §12.2.

PTSCRITERIO	DÓNDE
15Repositorio, proceso y buenas prácticas	§11 completa. Reproducibilidad (§3.4), observabilidad (§8), rastro del proceso de trabajo y uso de IA (§11.2), coherencia del informe con el repositorio (todo el documento).

B.3 Las métricas obligatorias del README

MÉTRICA EXIGIDA	ESTADO	DÓNDE
Latencia P50 y P95	Reportada	§8.3 y §8.4. El tramo desde el fin del habla está declarado sin muestras en las corridas reportadas y explicado en §8.5.
Tokens de entrada y salida por turno y por llamada	Reportada	§8.3
Invocaciones al modelo por turno	Reportada	§8.3 — exactamente 1,0
Consultas al RAG por llamada	Reportada	§8.3 — con la explicación del caso de 4,0 en §4.5
Costo estimado por llamada	Estimado	§8.3 — sobre tarifa pública, declarado como no confirmado contra la consola de la cuenta